

Архитектура пайплайна эмбедингов и кластеризации




Figure 1: Общая схема пайплайна: от сырых данных через эмбединги и кластеризацию к прогнозированию доходности и mean-variance оптимизации.

Предлагаемый в работе подход к анализу и последующему прогнозированию цен акций на Московской бирже базируется на идее перехода от непосредственной работы с сырыми временными рядами к работе с их латентными представлениями — эмбедингами. Основная гипотеза заключается в том, что поведение ценового графика на ограниченном временном горизонте (окне) может быть закодировано в некоторое векторное представление фиксированной размерности, причём близость таких представлений в латентном пространстве будет отражать схожесть динамики цены вне зависимости от абсолютных значений и конкретного инструмента. Гипотеза об эффективности конкретных инструментов сводится на практике к тому, что мы рассматриваем рынок - как структуру динамическую. Паттерны могут менять год от к году и те, что давали эффекты в прошлом могут быть убыточны сейчас. В то же время мы верим, что “Ничто не ново под луной”. На практике это означает, что новые алгоритмы и способы рассмотрения рынка появляются редко. Поэтому то, что для конкретного временного ряда может являться новым паттерном - могло встречаться ранее в других временных рядах (например, в других акциях).

Применение эмбедингов позволяет, во-первых, абстрагироваться от масштаба цен отдельных акций, а во-вторых, выявлять повторяющиеся паттерны поведения, которые могут соответствовать определённым рыночным режимам или фазам движения.

Пайплайн обработки данных и построения эмбедингов состоит из нескольких последовательных этапов, каждый из которых вносит вклад в формирование итогового латентного пространства и последующей интерпретации результатов. На вход всей системы поступают сырые данные по акциям Московской биржи, включающие стандартные для

анализа финансовых временных рядов параметры: цены открытия, закрытия, максимумы, минимумы и объёмы торгов. Важно отметить, что мы не отбираем только ликвидные акции - если бы мы так поступили, был бы велик шанс столкнуться с “look-ahead bias” - ошибкой, связанной с выбором акций, которые достоверно будут пользоваться популярностью и с большей вероятностью будут расти, что в свою очередь позволит быть прибыльными тем алгоритмам, которые на данных без этого смещения, эффективным не будут.

Выбор данных

Первым этапом является предварительная фильтрация и нормализация данных. Для каждого тикера выполняется очистка от пропусков и выбросов, после чего ценовые ряды приводятся к сопоставимому виду. В качестве основной техники нормализации используется приведение к логарифмической доходности либо масштабирование относительно локального окна, что позволяет нейтрализовать эффект различий в абсолютных ценах между разными акциями и сосредоточиться на форме движения, а не на его амплитуде. Такой подход особенно важен для последующей кластеризации, поскольку без нормализации бумаги с высокой ценой (например, акции Сбербанка) будут доминировать в пространстве признаков исключительно за счёт масштаба, а не за счёт характерной динамики.

Второй этап — формирование скользящих окон фиксированной длины. Каждое окно представляет собой непрерывную последовательность из (L) временных шагов (свечей), для которых известны все необходимые признаки. Выбор длины окна является критическим гиперпараметром и в данной работе обосновывается как компромисс между двумя факторами. С одной стороны, окно должно быть достаточно длинным, чтобы захватывать значимые паттерны, такие как краткосрочные тренды, развороты, консолидации или пробой уровней. С другой стороны, слишком длинное окно приводит к размыванию локальной структуры и увеличению вычислительной сложности.

путем перебора гиперпараметров было выбрано значение $L = 60$, что соответствует примерно десяти торговым дням при часовом таймфрейме или двум месяцам при дневном. Это окно, с одной стороны, достаточно для проявления типичных технических паттернов, а с другой — не настолько велико, чтобы включать несколько разнородных рыночных режимов одновременно, что усложнило бы задачу эмбединга.

Обучение сети

Третий этап — кодирование каждого окна в эмбединг фиксированной размерности с помощью рекуррентной нейронной сети. В качестве архитектуры кодировщика выбрана сеть на основе LSTM, что обусловлено способностью данного класса моделей удерживать долгосрочные зависимости в последовательности и при этом избегать затухания градиента, характерного для простых рекуррентных сетей. Архитектура кодировщика устроена следующим образом: на вход подаётся последовательность признаков окна размерности ($L \times d$), где (d) — число признаков на одну свечу (например, OHLCV даёт ($d=5$)). Далее последовательно проходит один или несколько слоёв LSTM, причём на последнем шаге скрытое состояние либо объединяется с состоянием ячейки, либо используется выход последнего временного шага в качестве агрегированного представления. В результате для каждого окна получается вектор ($e \in \mathbb{R}^h$), где (h) — размерность эмбединга, задаваемая как гиперпараметр (в эксперименте использовалось значение ($h=64$)).

Обучение кодировщика осуществляется в автоэнкодерной постановке или с использованием контрастивной цели, когда близкие по динамике окна должны получать близкие эмбединги, а далёкие — удалённые. Важно отметить, что кодировщик обучается на всей

совокупности окон по всем выбранным акциям, что позволяет ему вырабатывать универсальные представления, инвариантные к конкретному инструменту. После завершения обучения кодировщик фиксируется, и все окна пропускаются через него для получения эмбедингов, которые затем становятся объектами кластеризации.

Четвёртый этап — кластеризация полученных эмбедингов в латентном пространстве. Цель кластеризации — выделить группы окон, демонстрирующих схожее ценовое поведение, независимо от того, какой акции они принадлежат и в какой временной период они наблюдались. В качестве алгоритма кластеризации в работе используется (k)-means с последующим подбором оптимального числа кластеров по силуэтному коэффициенту и индексу Дэвиса–Боулдина. Альтернативно рассматривается иерархическая кластеризация, позволяющая визуализировать структуру сходства между эмбедингами в виде дендрограммы. Результатом этапа является разметка каждого окна меткой кластера, которая интерпретируется как принадлежность к определённого типу ценовой динамики.

Завершающим этапом пайплайна является анализ выделенных кластеров и их привязка к содержательным рыночным режимам. Для каждого кластера вычисляются статистические характеристики входящих в него окон: средняя волатильность, характерный наклон тренда, типичная амплитуда движения, а также временная и инструментальная структура. Это позволяет дать интерпретацию кластерам, например, выделить кластеры, соответствующие импульсному росту, боковой консолидации, высоковолатильным разнонаправленным движениям или плавному нисходящему тренду. Интерпретируемость кластеров критически важна для последующего этапа формирования портфеля и принятия торговых решений: если агент знает, что текущее окно относится к кластеру «высокая волатильность без тренда», он может снизить размер позиции или переключиться на менее рискованные активы.

Предложенный пайплайн позволяет перейти от хаотичного множества ценовых графиков к структурированному латентному пространству, в котором выделяются повторяющиеся поведенческие паттерны. Это создаёт основу для двух ключевых применений в рамках проекта. Во-первых, кластеризация эмбедингов может использоваться для адаптивного выбора прогнозной модели: в зависимости от того, к какому кластеру относится текущее окно, может применяться специализированная модель, обученная на окнах из того же кластера. Во-вторых, информация о кластерах может быть интегрирована в процесс формирования портфеля, например, путём ограничения или расширения набора рассматриваемых активов в зависимости от того, в каком режиме они находятся. Таким образом, пайплайн эмбедингов и кластеризации выступает не как самоцель, а как фундамент для построения более интеллектуальной и адаптивной торговой системы.