

Кластеризация эмбендингов

Кластеризация представляет собой процесс группировки объектов(в нашем случае эмбендингов) на основе их схожести.

Для кластеризации были использованы следующие методы:

- KMeans - метод кластеризации на основе k-средних
- HDBSCAN - метод кластеризации на основе DBSCAN

KMeans

KMeans - метод который принимает на вход k - количество кластеров и определяет центры кластеров.

Следующим шагом он считает расстояние от каждого объекта до центра кластера и относит его к тому кластеру, который находится ближе всего и пересчитывает центр кластера через среднее арифметическое координат объектов в кластере. Этот процесс продолжается до тех пор пока центры кластеров не стабилизируются.

Подбор оптимального количества кластеров проводился по метрике **silhouette** (коэффициент силуэта).

Пусть $d(i, j)$ — расстояние между объектами i и j в пространстве эмбендингов. Обозначим через $C(i)$ кластер, которому принадлежит объект i .

Внутрикластерная средняя дистанция:

$$a(i) = \frac{1}{|C(i)| - 1} \sum_{j \in C(i), j \neq i} d(i, j)$$

Минимальная средняя дистанция до «чужого» кластера:

$$b(i) = \min_{C \neq C(i)} \frac{1}{|C|} \sum_{j \in C} d(i, j)$$

Силуэт точки i :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Средний силуэт по выборке из n объектов:

$$\text{Silhouette} = \frac{1}{n} \sum_{i=1}^n s(i)$$

Чем ближе значение к 1, тем лучше разделимость кластеров, значения около 0 указывают на перекрытие кластеров.

Так как окна с большим пересечением с большой вероятностью принадлежат к одному кластеру, то было решено получать их не подряд с шагом 1 день, а с шагом 5 дня, что позволяет избежать сильного пересечения и не сильно уменьшить количество данных.

Визуализация и анализ кластеров

Метрики анализа кластеров

Для анализа кластеров были посчитаны следующие метрики:

- mean return - средняя доходности по кластеру, чтобы понимать какой кластер более прибыльный.
- std return - стандартное отклонение доходности по кластеру, для анализа рискованности кластера.
- sharpe(proxy) - коэффициент Шарпа по кластеру, которая описывает эффективность кластера.
- kurtosis - эксцесс доходности по кластеру, для анализа формы распределения доходности кластера.
- skewness - асимметрия доходности по кластеру, для анализа формы распределения доходности кластера.

TS2Vec




Figure 1: Визуализация кластеров TS2Vec

При использовании TS2Vec для построения эмбендингом наилучший результат получился для количества кластеров $k = 5$ и коэффициента силуэта $\text{silhouette} = 0.11$.




Figure 2: Распределение кластеров TS2Vec

Как видно из графика, кластеры содержат примерно одинаковое количество объектов. Это говорит о том, что кластеризация прошла успешно и не возникло вырожденных кластеров с критически малым числом элементов, на которых было бы невозможно обучить модель. Сбалансированность распределения свидетельствует о том, что алгоритм K-Means нашёл устойчивое разбиение пространства эмбедингов: ни один кластер не доминирует над остальными и не поглощает большую часть обучающей выборки. Это важное свойство с практической точки зрения — каждый кластер представляет собой отдельный режим рынка с достаточным количеством примеров для надёжного обучения специализированных моделей прогнозирования.




Figure 3: Метрики анализа кластеров TS2Vec

Кластер C0 — нейтральный (боковое движение). Все метрики данного кластера располагаются вблизи нулевой отметки на радарном графике. Средняя доходность и коэффициент Шарпа близки к нулю, волатильность умеренная, асимметрия и эксцесс не выражены. Такие окна соответствуют периодам рыночной неопределённости, когда цена движется в узком диапазоне без устойчивого тренда. С точки зрения торговой стратегии данный кластер наименее информативен и характеризует «боковик».

Кластер C1 — устойчивый рост (бычий тренд). Кластер демонстрирует наибольшую среднюю доходность и наиболее высокий прокси-коэффициент Шарпа среди всех кластеров. Волатильность при этом остаётся умеренной, что обеспечивает благоприятное соотношение доходности к риску. Положительная асимметрия распределения указывает на то, что редкие крупные прибыльные движения присутствуют чаще, чем убыточные выбросы. Данный кластер соответствует устойчивым бычьим периодам рынка, на которых длинные позиции наиболее эффективны.

Кластер C2 — высокая волатильность (нестабильный рынок). Отличительная черта кластера — значительно завышенное стандартное отклонение доходности и высокий эксцесс распределения. Это свидетельствует о наличии резких ценовых движений в обоих направлениях: как сильных ростов, так и глубоких падений. Средняя доходность при этом близка к нулю, а коэффициент Шарпа низкий, что делает прогнозирование направления

движения крайне затруднительным. Подобные режимы характерны для периодов выхода важных макроэкономических новостей или корпоративных событий.

Кластер С3 — снижение (медвежий тренд). Данный кластер характеризуется отрицательной средней доходностью и отрицательным значением прокси-коэффициента Шарпа, что однозначно указывает на медвежий режим рынка. Волатильность повышена, распределение имеет выраженную отрицательную асимметрию — убыточные движения в среднем превышают прибыльные. Окна этого кластера соответствуют периодам устойчивого снижения котировок, при которых короткие позиции или выход из рынка являются предпочтительной стратегией.

Кластер С4 — аномальный (экстремальные движения). Кластер выделяется высоким положительным скосом (skewness) при умеренных остальных показателях. Это указывает на нечастые, но очень крупные положительные выбросы доходности — так называемые «gap up» или ударные дни роста. Несмотря на умеренную среднюю доходность, хвост распределения значительно вытянут вправо. Такой профиль характерен для периодов резкого восстановления после коррекции или реакции на позитивные корпоративные события.

Из полученных результатов можно сделать вывод, что кластеры реально пределяют разные режимы рынка и гипотеза о том, что для разных режимов нужно использовать разные модели оправдывается.

Handmade