

Кластеризация эмбендингов

Кластеризация представляет собой процесс группировки объектов(в нашем случае эмбендингов) на основе их схожести.

Для кластеризации были использованы следующие методы:

- KMeans - метод кластеризации на основе k-средних
- HDBSCAN - метод кластеризации на основе DBSCAN

KMeans

KMeans - метод который принимает на вход k - количество кластеров и определяет центры кластеров.

Следующим шагом он считает расстояние от каждого объекта до центра кластера и относит его к тому кластеру, который находится ближе всего и пересчитывает центр кластера через среднее арифметическое координат объектов в кластере. Этот процесс продолжается до тех пор пока центры кластеров не стабилизируются.

Подбор оптимального количества кластеров проводился по метрике **silhouette** (коэффициент силуэта).

Пусть $d(i, j)$ — расстояние между объектами i и j в пространстве эмбендингов (например, евклидово). Обозначим через $C(i)$ кластер, которому принадлежит объект i .

Внутрикластерная средняя дистанция:

$$a(i) = \frac{1}{|C(i)| - 1} \sum_{j \in C(i), j \neq i} d(i, j)$$

(для кластера из одного объекта полагают $a(i) = 0$.)

Минимальная средняя дистанция до «чужого» кластера:

$$b(i) = \min_{C \neq C(i)} \frac{1}{|C|} \sum_{j \in C} d(i, j)$$

Силуэт точки i :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

если $|C(i)| > 1$ и существует хотя бы один другой кластер; иначе $s(i) = 0$.

Средний силуэт по выборке из n объектов:

$$\text{Silhouette} = \frac{1}{n} \sum_{i=1}^n s(i)$$

Чем ближе значение к 1, тем лучше разделимость кластеров; значения около 0 указывают на перекрытие кластеров.