

Работа с данными

Данные

В работе используются дневные данные о свечах всех валидных акций Московской биржи. Свечи базово включают 5 основных параметров помимо timestamp:

open	high	low	close	volume
------	------	-----	-------	--------

Где **open** - цена открытия свечи, **high** - максимальная цена свечи, **low** - минимальная цена свечи, **close** - цена закрытия свечи, **volume** - объём торгов.

Эти данные были собраны за период с начала существования акции на бирже вплоть до 2026 года.



Figure 1: Дневные свечи акции SBER

Предобработка данных и создание признаков

Перед добавлением признаков в данные были удалены пропуски, а также исключены все акции, у которых было менее 252 торговых дней.

Далее для каждого временного ряда были добавлены следующие признаки:

sma5	sma20
ema12	ema26
close_sma20	macd
macd_signal	macd_hist
rsi14	bb_pct
bb_bw	atr14
obv	

Где признаки вычисляются по формулам:

- $sma5_t = \frac{1}{5} \sum_{i=0}^4 close_{t-i}$ - средняя цена за 5 дней
- $sma20_t = \frac{1}{20} \sum_{i=0}^{19} close_{t-i}$ - средняя цена за 20 дней

- $\text{ema12}_t = \alpha_{12}\text{close}_t + (1 - \alpha_{12})\text{ema12}_{t-1}$, $\alpha_{12} = \frac{2}{12+1}$ - экспоненциальная средняя цена за 12 дней
- $\text{ema26}_t = \alpha_{26}\text{close}_t + (1 - \alpha_{26})\text{ema26}_{t-1}$, $\alpha_{26} = \frac{2}{26+1}$ - экспоненциальная средняя цена за 26 дней
- $\text{close_sma20}_t = \frac{\text{close}_t}{\text{sma20}_t}$ - отношение цены к средней цене за 20 дней
- $\text{macd}_t = \text{ema12}_t - \text{ema26}_t$ - разница между экспоненциальными средними за 12 и 26 дней
- $\text{macd_signal}_t = \text{ema9}(\text{macd}_t)$ - экспоненциальная скользящая средняя за 9 дней от macd_t
- $\text{macd_hist}_t = \text{macd}_t - \text{macd_signal}_t$ - разница между macd_t и macd_signal_t
- $\text{rsi14}_t = 100 - \frac{100}{1 + \text{RS}_t}$, $\text{RS}_t = \frac{\text{avgGain14}_t}{\text{avgLoss14}_t}$ - индекс относительной силы за 14 дней
- $\text{sigma20}_t = \text{std}(\text{close}_{t-19}, \dots, \text{close}_t)$ - стандартное отклонение цены за 20 дней
- $\text{bb_upper}_t = \text{sma20}_t + 2 \times \text{sigma20}_t$, $\text{bb_lower}_t = \text{sma20}_t - 2 \times \text{sigma20}_t$ - верхняя и нижняя границы полос Боллинджера
- $\text{bb_pct}_t = \frac{\text{close}_t - \text{bb_lower}_t}{\text{bb_upper}_t - \text{bb_lower}_t}$ - относительное положение цены внутри полос Боллинджера
- $\text{bb_bw}_t = \frac{\text{bb_upper}_t - \text{bb_lower}_t}{\text{sma20}_t}$ - ширина полос Боллинджера
- $\text{TR}_t = \max(\text{high}_t - \text{low}_t, \text{abs}(\text{high}_t - \text{close}_{t-1}), \text{abs}(\text{low}_t - \text{close}_{t-1}))$ - истинный диапазон
- $\text{atr14}_t = \text{ema14}(\text{TR}_t)$ - экспоненциальная средняя истинного диапазона за 14 дней
- $\text{obv}_t = \text{obv}_{t-1} + \text{sign}(\text{close}_t - \text{close}_{t-1}) \times \text{volume}_t$ - накопленный баланс объема торгов

Где close_t , high_t , low_t , volume_t — значения цены закрытия, максимума, минимума и объема в день t соответственно.

Таким образом, всего получается 18 признаков, на которых обучаются модели.

open	high
low	close
volume	sma5
sma20	ema12
ema26	close_sma20
macd	macd_signal
macd_hist	rsi14
bb_pct	bb_bw
atr14	obv

Все данные были разделены на три непересекающихся временных выборки: тренировочную, валидационную и тестовую. Разбиение выполнено по дате, а не случайно, чтобы исключить утечку данных из будущего в прошлое.

Поскольку часть акций появилась на МОЕХ лишь в 2014–2015 годах, тренировочная выборка охватывает наибольший временной промежуток.

Выборка	Период	Доля
Train	2000 — 2022	5/7

Validation	2023 — 2024	1/7
Test	2025 — март 2026	1/7