

Методы построения эмбедингов

Кластеризация временных окон возможна только после приведения их к единому векторному формату. Поэтому для каждого окна строится эмбединг — числовое представление, сохраняющее информацию о структуре и динамике временного ряда.

Для построения эмбедингов были использованы следующие методы:

- Handmade Embedder — метод построения эмбедингов на основе ручных статистических признаков.
- TS2Vec Embedder — метод построения эмбедингов на основе самообучаемой модели TS2Vec.

TS2Vec Embedder

TS2Vec — unsupervised метод построения эмбедингов временных рядов на основе иерархического контрастного обучения.

На каждой итерации модель получает окно временного ряда и порождает две аугментации: случайно обрезает начало/конец подпоследовательности и маскирует отдельные временные шаги.

Обе аугментации подаются в один и тот же энкодер, после чего вычисляется контрастная функция потерь: эмбединги одного и того же момента времени из разных аугментаций притягиваются, а эмбединги разных моментов — отталкиваются.

Энкодер состоит из проекционного слоя в размерность `hidden_dim` и `depth` дилатированных свёрточных блоков (TCN).

После энкодера представления проецируются в пространство размерности `output_dim`.




Figure 1: Схема архитектуры TS2Vec

Для построения эмбедингов был выбран `output_dim = 50` для окон длиной 60 дней. На обучающей выборке выполнен перебор гиперпараметров энкодера `hidden_dim` и `depth` с помощью Optuna.

Параметр	Значение
hidden_dim	128
depth	8
output_dim	50

Table 1: Гиперпараметры TS2Vec после подбора Optuna

Handmade Embedder

Handmade Embedder — детерминированный метод построения эмбеддингов, не требующий обучения. Для каждого окна длиной $T = 60$ дней вычисляется вектор из 15 признаков, который и является его эмбеддингом.

Обозначим z_t — z -нормированное значение close в момент t , v_t — volume, T — длина окна.

Трендовые признаки

- $\text{slope} = \frac{\sum_{t=1}^T (t-\bar{t})(z_t-\bar{z})}{\sum_{t=1}^T (t-\bar{t})^2}$ — линейный наклон ряда
- $\text{net_move} = z_T - z_1$ — суммарное ценовое движение от начала к концу окна
- $\text{frac_above_mean} = \frac{1}{T} \sum_{t=1}^T \mathbb{1}[z_t > \bar{z}]$ — доля баров, на которых цена выше среднего, значение 0.5 соответствует боковику, близкое к 0 или 1 — устойчивому тренду
- $\text{price_range} = \max_t z_t - \min_t z_t$ — размах ценового движения внутри окна

Волатильность

- $\text{daily_vol} = \text{std}(z_t - z_{t-1}, t = 2 \dots T)$ — стандартное отклонение дневных приращений
- $\text{skewness} = \frac{1}{T} \sum_{t=1}^T \left(\frac{z_t - \bar{z}}{\sigma_z} \right)^3$ — асимметрия распределения значений close, положительный снос указывает на редкие резкие подьёмы, отрицательный — на резкие падения
- $\text{kurtosis} = \frac{1}{T} \sum_{t=1}^T \left(\frac{z_t - \bar{z}}{\sigma_z} \right)^4 - 3$ — эксцесс, высокие значения указывают на тяжёлые хвосты и склонность к выбросам

Объёмные признаки

- $\text{price_vol_corr} = \frac{\sum_{t=1}^T \tilde{z}_t \tilde{v}_t}{\sqrt{\sum_{t=1}^T \tilde{z}_t^2 \cdot \sum_{t=1}^T \tilde{v}_t^2 + \varepsilon}}$ — корреляция цены и объёма, где $\tilde{z}_t = z_t - \bar{z}$, $\tilde{v}_t = v_t - \bar{v}$, положительные значения означают, что рост цены подтверждается объёмом
- $\text{vol_activity} = \text{std}(v_t - v_{t-1}, t = 2 \dots T)$ — стандартное отклонение приращений объёма, высокие значения характерны для периодов аномальной торговой активности

Снимок индикаторов в конце окна

- $\text{last_rsi} = \text{RSI}_T$ — значение RSI в последний день окна, отражает текущую перекупленность или перепроданность.
- $\text{last_macd_hist} = \text{MACD_hist}_T$ — значение MACD-гистограммы в конце окна, знак указывает на направление момента
- $\text{last_bb_pct} = \text{BB_pct}_T$ — значение BB%b в конце окна; показывает, где цена находится относительно полос Боллинджера.
- $\text{last_bb_bw} = \text{BB_bw}_T$ — ширина полос Боллинджера в конце окна; высокие значения соответствуют высокой волатильности.

Наклон индикаторов внутри окна

- $\text{rsi_slope} = \text{RSI}_T - \text{RSI}_1$ — изменение RSI от начала к концу окна, положительные значения указывают на нарастание импульса
- $\text{macd_slope} = \text{MACD_hist}_T - \text{MACD_hist}_1$ — изменение MACD-гистограммы, показывает, усиливается или затухает текущий импульс

Итоговый вектор эмбединга имеет размерность 15. Все нечисловые значения (NaN, Inf) заменяются нулём.