

- [1] G. E. P. Box and G. M. Jenkins, "Time Series Analysis: Forecasting and Control," *Holden-Day*, 1970.
- [2] S. Siامي-Namini, N. Tavakoli, and A. Siامي Namin, "A Comparative Analysis of Forecasting Financial Time Series Using ARIMA, LSTM, and BiLSTM," 2019.
- [3] T. Fischer and C. Krauss, "Deep learning with long short-term memory networks for financial market predictions," *European Journal of Operational Research*, vol. 270, no. 2, pp. 654–669, 2018, doi: 10.1016/j.ejor.2017.11.054.
- [4] K. Greff, R. K. Srivastava, J. Koutník, B. R. Steunebrink, and J. Schmidhuber, "LSTM: A Search Space Odyssey," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 28, no. 10, pp. 2222–2232, 2017.
- [5] K. Cho, B. van Merriënboer, Ç. Gülçehre, F. Bougares, H. Schwenk, and Y. Bengio, "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation," *arXiv preprint*, 2014.
- [6] "Integrated GARCH-GRU in Financial Volatility Forecasting," 2024.
- [7] G. Lai, W.-C. Chang, Y. Yang, and H. Liu, "Modeling Long- and Short-Term Temporal Patterns with Deep Neural Networks," *arXiv preprint*, 2017.
- [8] "Financial Time Series Forecasting using CNN and Transformer," 2024.
- [9] A. Vaswani *et al.*, "Attention Is All You Need," *arXiv preprint*, 2017.
- [10] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are Transformers Effective for Time Series Forecasting?," vol. 37, no. 9, pp. 11121–11128, 2023.
- [11] H. Zhou *et al.*, "Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting," in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2021, pp. 11106–11115.
- [12] O. B. Sezer, M. U. Gudelek, and A. M. Ozbayoglu, "Financial time series forecasting with deep learning: A systematic literature review: 2005–2019," *Applied Soft Computing*, vol. 90, p. 106181–106182, 2020, doi: 10.1016/j.asoc.2020.106181.
- [13] Е. А. Федорова and В. А. Черепенко, "Применение методов машинного обучения для прогнозирования доходности акций на российском фондовом рынке," *Экономический журнал ВШЭ*, vol. 24, no. 4, pp. 560–590, 2020.
- [14] G. Ke *et al.*, "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," vol. 30, 2017.
- [15] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A Next-generation Hyperparameter Optimization Framework," in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, ACM, 2019, pp. 2623–2631.
- [16] Z. Yue *et al.*, "TS2Vec: Towards Universal Representation of Time Series," in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2022, pp. 8980–8987.
- [17] S. P. Lloyd, "Least Squares Quantization in PCM," *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.
- [18] P. J. Rousseeuw, "Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.
- [19] T. Caliński and J. Harabasz, "A dendrite method for cluster analysis," *Communications in Statistics*, vol. 3, no. 1, pp. 1–27, 1974.

- [20] R. J. G. B. Campello, D. Moulavi, and J. Sander, "Density-Based Clustering Based on Hierarchical Density Estimates," in *Advances in Knowledge Discovery and Data Mining (PAKDD)*, Springer, 2013, pp. 160–172.
- [21] L. McInnes, J. Healy, and J. Melville, "UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction," *arXiv preprint*, 2018.
- [22] H. Markowitz, "Portfolio Selection," *The Journal of Finance*, vol. 7, no. 1, pp. 77–91, 1952.
- [23] R. Kan and G. Zhou, "Optimal Portfolio Choice with Parameter Uncertainty," *Journal of Financial and Quantitative Analysis*, vol. 42, no. 3, pp. 621–656, 2007, doi: 10.1017/S0022109000004129.
- [24] O. Ledoit and M. Wolf, "A well-conditioned estimator for large-dimensional covariance matrices," *Journal of Multivariate Analysis*, vol. 88, no. 2, pp. 365–411, 2004.
- [25] W. F. Sharpe, "The Sharpe Ratio," *The Journal of Portfolio Management*, vol. 21, no. 1, pp. 49–58, 1994.
- [26] T. W. Young, "Calmar Ratio: A Smoother Tool," *Futures Magazine*, vol. 20, no. 1, 1991.
- [27] D. H. Bailey and M. López de Prado, "The Deflated Sharpe Ratio: Correcting for Selection Bias," *The Journal of Portfolio Management*, vol. 40, no. 5, pp. 94–107, 2014.
- [28] X. Shi, Y. Liu, W. Chen, and J. Liu, "On Evaluating Loss Functions for Stock Ranking: An Empirical Analysis With Transformer Model," *arXiv preprint*, 2024.
- [29] C. Truong, L. Oudre, and N. Vayatis, "Selective review of offline change point detection methods," *arXiv preprint*, 2018.

Обзор литературы

Прогнозирование финансовых временных рядов

Задача прогнозирования финансовых временных рядов является одной из наиболее исследуемых в области машинного обучения и эконометрики. Классический подход — авторегрессионные модели семейства ARIMA [1], которые долгое время оставались стандартом в задачах краткосрочного прогнозирования. Сравнительный анализ ARIMA, LSTM и BiLSTM [2] показал, что нейросетевые модели превосходят классические на нелинейных и нестационарных рядах, характерных для фондового рынка.

С развитием глубокого обучения интерес исследователей сместился в сторону рекуррентных архитектур. Работа [3] стала одной из первых, систематически продемонстрировавших преимущество LSTM [4] перед классическими методами на данных фондовых бирж. Архитектура GRU [5], предложенная как упрощение LSTM с меньшим числом параметров, также нашла широкое применение в задачах прогнозирования, в том числе в гибридных моделях совместно с GARCH [6].

Свёрточные нейронные сети (CNN) применяются для извлечения локальных паттернов из временных рядов. Модель LSTNet [7] совмещает CNN и LSTM, что позволяет улавливать как краткосрочные, так и долгосрочные зависимости. Совместное применение CNN и Transformer для финансовых рядов исследовалось в [8].

Механизм внимания, введённый в работе [9], открыл новое направление в моделировании последовательностей. Однако применительно к финансовым рядам его эффективность остаётся предметом дискуссий: авторы [10] показали, что на ряде задач простые линейные

модели сопоставимы с Transformer по качеству. Архитектура Informer [11] адаптирует Transformer для длинных временных рядов за счёт разреженного механизма внимания.

Систематический обзор методов глубокого обучения для финансовых рядов за период 2005–2019 годов представлен в [12], где авторы выделяют рекуррентные сети как наиболее распространённый подход, а также отмечают растущий интерес к ансамблевым и гибридным методам.

Применение методов машинного обучения на российском фондовом рынке изучалось в [13], где показано, что градиентный бустинг и нейросетевые модели обеспечивают значимый прирост качества прогноза по сравнению с линейными регрессиями.

Градиентный бустинг и оптимизация гиперпараметров

LightGBM [14] — высокоэффективная реализация градиентного бустинга на деревьях решений, широко применяемая в задачах прогнозирования финансовых рядов благодаря скорости обучения и устойчивости к выбросам. Для автоматического подбора гиперпараметров в настоящей работе используется фреймворк Optuna [15], реализующий байесовскую оптимизацию с алгоритмом Tree-structured Parzen Estimator (TPE).

Представление временных рядов и кластеризация

Для кластеризации временных рядов необходимо привести их к единому векторному формату. Алгоритм TS2Vec [16] предлагает универсальный метод построения эмбедингов временных рядов на основе иерархического контрастного обучения, позволяющий получать представления, инвариантные к масштабу и смещению.

Для кластеризации в работе применяется алгоритм KMeans [17]. В качестве метрики качества разбиения используется коэффициент силуэта [18], а также индексы Калински–Харабаша [19]. Дополнительно исследуется плотностной метод HDBSCAN [20], позволяющий выделять кластеры произвольной формы без заданного числа k и автоматически помечать выбросы как шум.

Для визуализации многомерных эмбедингов применяется метод снижения размерности UMAP [21], сохраняющий как локальную, так и глобальную структуру данных.

Оптимизация портфеля

Фундаментальным результатом в области формирования портфелей является теория среднedisперсионной оптимизации Марковица [22], в рамках которой задача выбора весов активов сводится к максимизации ожидаемой доходности при заданном уровне риска. Практическая применимость подхода ограничена чувствительностью к оценкам ковариационной матрицы: работа [23] исследует влияние ошибок оценки параметров на качество портфеля. Для получения устойчивых оценок ковариации в условиях высокой размерности используется регуляризованный оценщик Леду–Вулфа [24].

Метрики оценки торговых стратегий

Коэффициент Шарпа [25] является стандартной мерой качества торговой стратегии, сопоставляющей избыточную доходность с её волатильностью. Коэффициент Калмара [26] соотносит годовую доходность с максимальной просадкой и особенно информативен для стратегий с ограниченным числом сделок. Вопросы статистической значимости показателей бэктестирования, в частности проблема множественного тестирования, рассмотрены в [27].

Выбор функции потерь при обучении ранжирующих моделей существенно влияет на торговые метрики: в [28] показано, что оптимизация по ранговым метрикам, в частности по IC, предпочтительнее MSE для задачи отбора акций.

Обнаружение режимов рынка

Финансовые рынки характеризуются чередованием различных режимов — бычьего, медвежьего, высоковолатильного и нейтрального. Методы обнаружения точек смены режима рассматриваются в [29], где авторы систематически сравнивают алгоритмы офлайн-детекции. Применение моделей Markov Switching AutoRegression позволяет явно моделировать переключения между режимами и строить прогнозы, адаптированные к текущему состоянию рынка.

Гипотеза о целесообразности специализации моделей по рыночным режимам подкреплена практическими результатами: специализированные модели стабильно превосходят универсальные на трендовых и кризисных периодах, тогда как в нейтральных режимах выигрыш от специализации минимален.