

- [1] G. E. P. Box and G. M. Jenkins, "Time Series Analysis: Forecasting and Control," *Holden-Day*, 1970.
- [2] S. Siامي-Namini, N. Tavakoli, and A. Siامي Namin, "A Comparative Analysis of Forecasting Financial Time Series Using ARIMA, LSTM, and BiLSTM," 2019.
- [3] T. Fischer and C. Krauss, "Deep learning with long short-term memory networks for financial market predictions," *European Journal of Operational Research*, vol. 270, no. 2, pp. 654–669, 2018, doi: 10.1016/j.ejor.2017.11.054.
- [4] K. Greff, R. K. Srivastava, J. Koutník, B. R. Steunebrink, and J. Schmidhuber, "LSTM: A Search Space Odyssey," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 28, no. 10, pp. 2222–2232, 2017.
- [5] K. Cho, B. van Merriënboer, Ç. Gülçehre, F. Bougares, H. Schwenk, and Y. Bengio, "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation," *arXiv preprint*, 2014.
- [6] "Integrated GARCH-GRU in Financial Volatility Forecasting," 2024.
- [7] G. Lai, W.-C. Chang, Y. Yang, and H. Liu, "Modeling Long- and Short-Term Temporal Patterns with Deep Neural Networks," *arXiv preprint*, 2017.
- [8] "Financial Time Series Forecasting using CNN and Transformer," 2024.
- [9] A. Vaswani *et al.*, "Attention Is All You Need," *arXiv preprint*, 2017.
- [10] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are Transformers Effective for Time Series Forecasting?," vol. 37, no. 9, pp. 11121–11128, 2023.
- [11] H. Zhou *et al.*, "Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting," in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2021, pp. 11106–11115.
- [12] O. B. Sezer, M. U. Gudelek, and A. M. Ozbayoglu, "Financial time series forecasting with deep learning: A systematic literature review: 2005–2019," *Applied Soft Computing*, vol. 90, p. 106181–106182, 2020, doi: 10.1016/j.asoc.2020.106181.
- [13] E. A. Федорова and B. A. Черепенко, "Применение методов машинного обучения для прогнозирования доходности акций на российском фондовом рынке," *Экономический журнал ВШЭ*, vol. 24, no. 4, pp. 560–590, 2020.
- [14] G. Ke *et al.*, "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," vol. 30, 2017.
- [15] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A Next-generation Hyperparameter Optimization Framework," in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, ACM, 2019, pp. 2623–2631.
- [16] Z. Yue *et al.*, "TS2Vec: Towards Universal Representation of Time Series," in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2022, pp. 8980–8987.
- [17] S. P. Lloyd, "Least Squares Quantization in PCM," *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.
- [18] P. J. Rousseeuw, "Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.
- [19] T. Caliński and J. Harabasz, "A dendrite method for cluster analysis," *Communications in Statistics*, vol. 3, no. 1, pp. 1–27, 1974.

- [20] R. J. G. B. Campello, D. Moulavi, and J. Sander, "Density-Based Clustering Based on Hierarchical Density Estimates," in *Advances in Knowledge Discovery and Data Mining (PAKDD)*, Springer, 2013, pp. 160–172.
- [21] L. McInnes, J. Healy, and J. Melville, "UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction," *arXiv preprint*, 2018.
- [22] H. Markowitz, "Portfolio Selection," *The Journal of Finance*, vol. 7, no. 1, pp. 77–91, 1952.
- [23] R. Kan and G. Zhou, "Optimal Portfolio Choice with Parameter Uncertainty," *Journal of Financial and Quantitative Analysis*, vol. 42, no. 3, pp. 621–656, 2007, doi: 10.1017/S0022109000004129.
- [24] O. Ledoit and M. Wolf, "A well-conditioned estimator for large-dimensional covariance matrices," *Journal of Multivariate Analysis*, vol. 88, no. 2, pp. 365–411, 2004.
- [25] W. F. Sharpe, "The Sharpe Ratio," *The Journal of Portfolio Management*, vol. 21, no. 1, pp. 49–58, 1994.
- [26] T. W. Young, "Calmar Ratio: A Smoother Tool," *Futures Magazine*, vol. 20, no. 1, 1991.
- [27] D. H. Bailey and M. López de Prado, "The Deflated Sharpe Ratio: Correcting for Selection Bias," *The Journal of Portfolio Management*, vol. 40, no. 5, pp. 94–107, 2014.
- [28] X. Shi, Y. Liu, W. Chen, and J. Liu, "On Evaluating Loss Functions for Stock Ranking: An Empirical Analysis With Transformer Model," *arXiv preprint*, 2024.
- [29] C. Truong, L. Oudre, and N. Vayatis, "Selective review of offline change point detection methods," *arXiv preprint*, 2018.

Обзор литературы

Прогнозирование финансовых временных рядов

Задача прогнозирования финансовых временных рядов является одной из наиболее исследуемых в области машинного обучения и эконометрики. Классический подход — авторегрессионные модели семейства ARIMA [1], которые долгое время оставались стандартом в задачах краткосрочного прогнозирования. Сравнительный анализ ARIMA, LSTM и BiLSTM [2] показал, что нейросетевые модели превосходят классические на нелинейных и нестационарных рядах, характерных для фондового рынка.

С развитием глубокого обучения интерес исследователей сместился в сторону рекуррентных архитектур. Работа [3] стала одной из первых, систематически продемонстрировавших преимущество LSTM [4] перед классическими методами на данных фондовых бирж. Архитектура GRU [5], предложенная как упрощение LSTM с меньшим числом параметров, также нашла широкое применение в задачах прогнозирования, в том числе в гибридных моделях совместно с GARCH [6].

Свёрточные нейронные сети (CNN) применяются для извлечения локальных паттернов из временных рядов. Модель LSTNet [7] совмещает CNN и LSTM, что позволяет улавливать как краткосрочные, так и долгосрочные зависимости. Совместное применение CNN и Transformer для финансовых рядов исследовалось в [8].

Механизм внимания, введённый в работе [9], открыл новое направление в моделировании последовательностей. Однако применительно к финансовым рядам его эффективность остаётся предметом дискуссий: авторы [10] показали, что на ряде задач простые линейные

модели сопоставимы с Transformer по качеству. Архитектура Informer [11] адаптирует Transformer для длинных временных рядов за счёт разреженного механизма внимания.

Систематический обзор методов глубокого обучения для финансовых рядов за период 2005–2019 годов представлен в [12], где авторы выделяют рекуррентные сети как наиболее распространённый подход, а также отмечают растущий интерес к ансамблевым и гибридным методам.

Применение методов машинного обучения на российском фондовом рынке изучалось в [13], где показано, что градиентный бустинг и нейросетевые модели обеспечивают значимый прирост качества прогноза по сравнению с линейными регрессиями.

Градиентный бустинг и оптимизация гиперпараметров

LightGBM [14] — высокоэффективная реализация градиентного бустинга на деревьях решений, широко применяемая в задачах прогнозирования финансовых рядов благодаря скорости обучения и устойчивости к выбросам. Для автоматического подбора гиперпараметров в настоящей работе используется фреймворк Optuna [15], реализующий байесовскую оптимизацию с алгоритмом Tree-structured Parzen Estimator (TPE).

Представление временных рядов и кластеризация

Для кластеризации временных рядов необходимо привести их к единому векторному формату. Алгоритм TS2Vec [16] предлагает универсальный метод построения эмбедингов временных рядов на основе иерархического контрастного обучения, позволяющий получать представления, инвариантные к масштабу и смещению.

Для кластеризации в работе применяется алгоритм KMeans [17]. В качестве метрики качества разбиения используется коэффициент силуэта [18], а также индексы Калински–Харабаша [19]. Дополнительно исследуется плотностной метод HDBSCAN [20], позволяющий выделять кластеры произвольной формы без заданного числа k и автоматически помечать выбросы как шум.

Для визуализации многомерных эмбедингов применяется метод снижения размерности UMAP [21], сохраняющий как локальную, так и глобальную структуру данных.

Оптимизация портфеля

Фундаментальным результатом в области формирования портфелей является теория среднedisперсионной оптимизации Марковица [22], в рамках которой задача выбора весов активов сводится к максимизации ожидаемой доходности при заданном уровне риска. Практическая применимость подхода ограничена чувствительностью к оценкам ковариационной матрицы: работа [23] исследует влияние ошибок оценки параметров на качество портфеля. Для получения устойчивых оценок ковариации в условиях высокой размерности используется регуляризованный оценщик Леду–Вулфа [24].

Метрики оценки торговых стратегий

Коэффициент Шарпа [25] является стандартной мерой качества торговой стратегии, сопоставляющей избыточную доходность с её волатильностью. Коэффициент Калмара [26] соотносит годовую доходность с максимальной просадкой и особенно информативен для стратегий с ограниченным числом сделок. Вопросы статистической значимости показателей бэктестирования, в частности проблема множественного тестирования, рассмотрены в [27].

Выбор функции потерь при обучении ранжирующих моделей существенно влияет на торговые метрики: в [28] показано, что оптимизация по ранговым метрикам, в частности по IC, предпочтительнее MSE для задачи отбора акций.

Обнаружение режимов рынка

Финансовые рынки характеризуются чередованием различных режимов — бычьего, медвежьего, высоковолатильного и нейтрального. Методы обнаружения точек смены режима рассматриваются в [29], где авторы систематически сравнивают алгоритмы офлайн-детекции. Применение моделей Markov Switching AutoRegression позволяет явно моделировать переключения между режимами и строить прогнозы, адаптированные к текущему состоянию рынка.

Гипотеза о целесообразности специализации моделей по рыночным режимам подкреплена практическими результатами: специализированные модели стабильно превосходят универсальные на трендовых и кризисных периодах, тогда как в нейтральных режимах выигрыш от специализации минимален.

Научная польза и новизна проекта заключаются в том, что он предлагает новый подход к прогнозированию цен акций, используя специально обученную модель под выделенные паттерны рынка, что позволяет более точно прогнозировать цены акций. Актуальность исследованию придаёт тот факт, что вся работа была проделана на акциях Московской биржи, для которой написано сравнительно мало статей подобного типа.