

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчет о программном проекте на тему:
Алгоритмы предсказания цены и оптимизации

(промежуточный, этап 1)

Выполнили студенты:

группы #БПИ234, 3 курса
группы #БПИ233, 3 курса
группы #БПИ2310, 3 курса

Шадрин Андрей Романович
Климов Демьян Дмитриевич
Барсуков Борис Михайлович

Принял руководитель проекта:

Мунерман Илья Викторович
Руководитель Интерфакс-ЛАБ, к.э.н.

Москва 2026

Содержание

Аннотация	3
Ключевые слова	3
Введение	4
1 Описание используемых алгоритмов	5
1.1 Обнаружение точек смены режима	5
1.2 Рекуррентные нейронные сети (RNN, LSTM, GRU)	5
1.3 Свёрточные нейронные сети для временных рядов	8
1.4 Модели на основе механизма внимания (Transformer)	9
1.5 Формирование портфеля и оптимизация по риску	9
1.6 Метрики качества прогноза и эффективности стратегии	10
2 План работы	11
2.1 Подготовка и анализ данных	11
2.2 Обучение моделей прогнозирования	11
2.3 Формирование и оптимизация портфеля	11
2.4 Реализация торгового агента	11
2.5 Бэктестирование и оценка результатов	12
Список литературы	12

Аннотация

В работе рассматривается задача прогнозирования цен акций на Московской бирже и формирования на этой основе инвестиционного портфеля. Планируется построить модель предсказания цен, использовать её для отбора бумаг и расчёта весов портфеля и в конечном итоге реализовать торгового агента, способного принимать решения о сделках на бирже с целью получения прибыли. Эффективность подхода будет проверяться на исторических данных и при бэктестировании. Практический результат — прототип системы прогнозирования, формирования портфеля и автоматизированной торговли на МОЕХ с оценкой потенциальной доходности и рисков.

Ключевые слова

прогнозирование цен, Московская биржа, формирование портфеля, торговый агент, алгоритмическая торговля, бэктестирование, машинное обучение

Введение

Рынок акций Московской биржи привлекает инвесторов и трейдеров, при этом ручной отбор бумаг и выбор моментов сделок трудно масштабировать и формализовать. Классическая оптимизация портфеля по Марковицу [1] опирается на оценки доходностей и ковариаций и часто даёт нестабильные результаты на реальных данных. Идея работы — использовать прогноз цен акций на МОЕХ, построенный при помощи алгоритмов и моделей машинного обучения, для формирования портфеля и дальнейшей реализации торгового агента, который на основе этих прогнозов и правил управления риском будет принимать решения о сделках и стремиться к получению прибыли.

Объект исследования — методы прогнозирования цен акций и формирования инвестиционного портфеля на российском рынке.

Предмет — построение системы прогноза, отбора бумаг и автоматизированной торговли на Московской бирже.

Цель — разработка подхода к прогнозированию цен акций на МОЕХ, формированию на этой основе пакета акций и под управлением торгового агента, способного торговать на бирже с целью получения прибыли.

Задачи:

1. Выбрать модель прогноза и критерии отбора бумаг и весов.
2. Спроектировать и реализовать торгового агента, работающего на исторических данных МОЕХ.
3. Провести бэктест, оценить потенциальную доходность и риски.

Научная новизна:

Существующие исследования по применению методов машинного обучения к прогнозированию российского рынка [2] сфокусированы главным образом на оценке доходности отдельных инструментов, однако комплексные системы, интегрирующие прогнозирование временных рядов цен акций МОЕХ на основе современных архитектур глубокого обучения и формирования портфеля, представлены в литературе ограниченно.

1 Описание используемых алгоритмов

В главе приведено описание алгоритмов и методов, которые планируется использовать в проекте: предобработка временных рядов с обнаружением точек смены режима, модели прогнозирования (RNN, LSTM, GRU, CNN, Transformer), формирование портфеля и метрики оценки. Все перечисленные методы будут задействованы на этапах плана работы.

1.1 Обнаружение точек смены режима

При работе с рыночными данными Московской биржи важно выявлять структурные сдвиги во временных рядах (изменение волатильности, тренда или режима торгов). Для этого планируется использовать методы **обнаружения точек смены режима** (Change Point Detection).

Принцип работы [3]. Алгоритмы офлайн-обнаружения разбивают ряд на сегменты так, чтобы внутри каждого сегмента данные удовлетворяли выбранной модели (например, постоянное среднее или стационарное распределение), а в точках смены параметры модели менялись. Формально задаётся **функция потерь** (cost function) — сумма по сегментам «стоимости» подгонки модели на этом сегменте; **метод поиска** находит разбиение, минимизирующее суммарную стоимость при заданном числе точек смены (или с штрафом за их количество). Используются точные методы (динамическое программирование, перебор) или приближённые (жадные, бинарная сегментация). Рассматриваются как офлайн-методы (ретроспективный анализ всего ряда), так и онлайн-методы для потоковых данных.

Применение методов обнаружения точек смены режима в финансовых данных. В работе [4] проведена сравнительная оценка различных алгоритмов обнаружения точек смены режима применительно к финансовым временным рядам. Финансовые данные характеризуются наличием структурных изменений, вызванных экономическими шоками, изменениями в регуляторной политике, сменами рыночных режимов (от бычьего к медвежьему рынку и наоборот), а также изменениями в волатильности. Обнаружение таких точек смены режима критично для корректного моделирования и прогнозирования, так как применение единой модели ко всему временному ряду может привести к значительным ошибкам, если данные содержат несколько различных режимов.

Методы обнаружения точек смены режима в финансах применяются для сегментации исторических данных на периоды с различными статистическими свойствами (например, периоды высокой и низкой волатильности, трендовые и боковые движения), что позволяет адаптировать модели прогнозирования к текущему режиму рынка. В проекте предполагается применять офлайн-обнаружение для разметки режимов рынка и возможной сегментации данных при подготовке обучающих выборок, в том числе с использованием реализаций из библиотеки **ruptures**.

1.2 Рекуррентные нейронные сети (RNN, LSTM, GRU)

Рекуррентные сети предназначены для обработки последовательностей и учёта временной зависимости. Классическая архитектура RNN [5] на каждом шаге времени t обновляет скрытое состояние h_t на основе текущего входа x_t и предыдущего состояния h_{t-1} :

$$h_t = \varphi(W_{xh}x_t + W_{hh}h_{t-1} + b_h) \quad (1.1)$$

где φ — нелинейная функция активации (например, $\tanh$), W_{xh} , W_{hh} — матрицы весов, b_h — смещение. Выход на шаге t может вычисляться как $y_t = W_{hy}h_t + b_y$. Обучение выполняется методом обратного распространения во времени (BPTT). Недостаток простых RNN — затухание или взрыв градиента при длинных последовательностях, что затрудняет обучение долгосрочным зависимостям.

Долгая краткосрочная память (LSTM) [6] вводит ячейку памяти C_t и три воротых механизма (ворота забывания, входа и выхода), управляющих потоком информации. На каждом шаге t вычисляются: **ворота забывания** $f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + b_f)$ — доля информации из ячейки C_{t-1} , которую сохраняем; **ворота входа** $i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + b_i)$ и кандидат на обновление ячейки $\tilde{C}_t = \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c)$; обновление ячейки $C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$ (звездочка — поэлементное умножение); **ворота выхода** $o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + b_o)$; скрытое состояние $h_t = o_t * \tanh(C_t)$. Функция σ — сигмоида, выходы ворот в $[0, 1]$, что позволяет стабильно передавать градиент через ячейку и смягчать проблему затухающего градиента.

Применение LSTM в финансовых временных рядах. Экспериментальные исследования показывают, что LSTM-модели превосходят традиционные методы временных рядов, такие как ARIMA, с существенным отрывом при прогнозировании финансовых данных [7]. В работе [7] проведено сравнительное исследование ARIMA, одностороннего LSTM и двунаправленного LSTM (BiLSTM) на данных акций IBM. Результаты демонстрируют, что глубокие нейронные сети с памятью, такие как LSTM, превосходят регрессионные подходы благодаря способности моделировать нелинейные зависимости и запоминать длинные последовательности входных данных через механизм ворот.

В задачах прогнозирования цен акций LSTM-сети применяются для предсказания будущих значений на основе исторических данных. Модель обучается на последовательностях фиксированной длины, где каждое окно содержит признаки за определённый период, и предсказывает значение цены на следующий временной шаг. Эксперименты [7] показывают, что LSTM-модели обрабатывают данные в одном направлении (слева направо), деля их на батчи размером 41-42 элемента, и достигают равновесия быстрее, чем двунаправленные варианты.

Двунаправленный LSTM (BiLSTM) в финансах. Архитектура BiLSTM расширяет возможности обычного LSTM за счёт дополнительного обучения данных в обратном направлении (справа налево), что позволяет модели учитывать как прошлые, так и будущие контексты при обработке каждого элемента последовательности [7]. Экспериментальные результаты [7] демонстрируют, что BiLSTM превосходит односторонний LSTM на 37.78% по снижению ошибок прогнозирования при работе с финансовыми временными рядами. Это улучшение достигается за счёт того, что модель обучается на данных дважды: сначала в прямом направлении (от прошлого к будущему), затем в обратном (от будущего к прошлому), что позволяет извлекать дополнительные паттерны из данных.

Интересной особенностью BiLSTM, выявленной в [7], является то, что модель делит те же данные на большее количество батчей (71-75 против 41-42 у обычного LSTM), используя меньшие размеры батчей. Это связано с тем, что BiLSTM должна обрабатывать данные в обоих направлениях, и длина обучающих данных, обрабатываемых каждым батчем, составляет примерно половину от длины батча в обычном LSTM. Кроме того,

BiLSTM достигает равновесия медленнее, чем односторонний LSTM, что указывает на способность модели извлекать дополнительные признаки из данных, которые не могут быть обнаружены при одностороннем обучении.

Сеть с блоками сброса ворот (GRU) [8] упрощает LSTM, используя два воротых блока. **Ворота сброса** $r_t = \sigma(W_{xr}x_t + W_{hr}h_{t-1} + b_r)$ определяют, какую часть прошлого состояния учитывать при формировании кандидата. **Ворота обновления** $z_t = \sigma(W_{xz}x_t + W_{hz}h_{t-1} + b_z)$ задают баланс между старым состоянием и новым. Кандидат скрытого состояния: $\tilde{h}_t = \tanh(W_{xh}x_t + (r_t * h_{t-1})W_{hh} + b_h)$. Итоговое состояние: $h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$. Таким образом, GRU объединяет идеи ворот забывания и входа LSTM в один механизм обновления; при меньшем числе параметров качество часто сопоставимо с LSTM, обучение быстрее.

Применение GRU в прогнозировании финансовой волатильности. В работе [9] предложена гибридная модель, объединяющая GARCH (Generalized Autoregressive Conditional Heteroskedasticity) и GRU для прогнозирования волатильности финансовых временных рядов. GARCH-модели традиционно используются для моделирования условной гетероскедастичности (изменяющейся во времени волатильности) в финансовых данных, но имеют ограничения при работе с нелинейными зависимостями. Интеграция GRU с GARCH позволяет комбинировать преимущества статистических моделей волатильности с способностью глубоких нейронных сетей улавливать сложные нелинейные паттерны. В такой гибридной архитектуре GARCH-компонент обеспечивает структурированное моделирование условной дисперсии, а GRU-компонент извлекает дополнительные нелинейные зависимости из остатков и других признаков, что улучшает точность прогнозирования волатильности по сравнению с использованием только GARCH или только GRU.

Рекуррентные сети с механизмом внимания для долгосрочного прогнозирования. Традиционные RNN, LSTM и GRU эффективны для одношагового и краткосрочного прогнозирования, но сталкиваются с трудностями при долгосрочном прогнозировании многомерных финансовых временных рядов [10]. Ключевая проблема долгосрочного прогнозирования заключается в необходимости одновременного захвата трёх типов зависимостей: пространственных корреляций между различными атрибутами в один момент времени, пространственно-временных отношений между различными атрибутами в разные моменты времени, и временных зависимостей между различными рядами [10].

Механизм внимания в RNN позволяет модели динамически определять веса различных входных признаков и временных шагов, что улучшает способность модели извлекать релевантную информацию из многомерных временных рядов. В работе [10] предложена архитектура DSTP-RNN (Dual-Stage Two-Phase RNN), вдохновлённая моделью человеческого внимания DSTP (Dual-Stage Two-Phase). Модель использует двухэтапную структуру внимания: на первом этапе производится сильный, но децентрализованный отклик весов внимания, а на втором этапе формируется стационарный и сконцентрированный отклик, что позволяет более точно моделировать пространственные корреляции между экзогенными рядами и целевым рядом.

В финансовом контексте DSTP-RNN применяется для долгосрочного прогнозирования многомерных временных рядов, где необходимо учитывать взаимосвязи между

различными финансовыми инструментами, индикаторами и макроэкономическими факторами. Модель использует множественные механизмы внимания на целевом ряде для усиления долгосрочных зависимостей, а также глубокий механизм пространственного внимания для извлечения сложных пространственных паттернов. Экспериментальные результаты [10] показывают, что attention-based RNN модели превосходят базовые методы на наборах данных в области финансов, энергии, окружающей среды и медицины, демонстрируя эффективность механизма внимания для долгосрочного прогнозирования многомерных временных рядов.

В проекте RNN, LSTM и GRU планируется использовать как базовые и сравнительные модели прогнозирования цен акций на MOEX, а также рассматривать варианты с механизмом внимания для улучшения долгосрочного прогнозирования.

1.3 Свёрточные нейронные сети для временных рядов

Свёрточные сети для одномерных временных рядов применяют **одномерную свёртку**: по оси времени скользит ядро (фильтр) длины k , на каждом сдвиге вычисляется скалярное произведение между фрагментом ряда и весами ядра плюс смещение, после чего применяется нелинейность. Таким образом извлекаются локальные паттерны (краткосрочные зависимости) в окне длины k . Несколько фильтров дают карту признаков; за свёрточными слоями могут следовать пулинг (усреднение или максимум по подпоследовательностям) для уменьшения размерности и агрегирования. В отличие от RNN, свёртки не имеют явного состояния между шагами и обрабатывают фиксированное окно; зато обучение параллелизуется по времени. Для прогноза ряда свёрточные блоки часто комбинируют с рекуррентными слоями или с полносвязными выходными слоями.

Применение CNN в прогнозировании финансовых временных рядов. В работе [11] исследуется применение свёрточных нейронных сетей для прогнозирования финансовых временных рядов. CNN-модели эффективно извлекают локальные паттерны и краткосрочные зависимости из временных рядов цен акций, используя одномерные свёрточные фильтры, которые скользят по временной оси. Это позволяет модели распознавать повторяющиеся паттерны, такие как технические фигуры, краткосрочные тренды и локальные аномалии в данных. В финансовом контексте CNN могут обрабатывать многомерные входные данные, включающие различные признаки (цены открытия, закрытия, максимумы, минимумы, объёмы), применяя свёртки как по временной оси, так и по оси признаков, что позволяет моделировать взаимосвязи между различными финансовыми показателями.

В работе [12] предложена архитектура **LSTNet** (Long- and Short-Term Time-series Network): сначала **свёрточный модуль** с одномерными фильтрами по времени извлекает краткосрочные локальные зависимости между переменными (при многомерном ряде — по всем каналам); затем выход свёрток подаётся в **рекуррентный модуль** (LSTM или GRU) для моделирования долгосрочных трендов; дополнительно может использоваться **авторегрессионный** линейный компонент для учёта масштаба ряда и устойчивости к нестационарности. В проекте планируется рассматривать как чисто свёрточные модели, так и гибриды CNN+RNN (в духе LSTNet) для прогноза цен акций.

1.4 Модели на основе механизма внимания (Transformer)

Архитектура **Transformer** [13] полностью основана на механизме **самовнимания** (self-attention) и не использует рекуррентные или свёрточные слои для кодирования порядка. Это даёт параллелизацию по длине последовательности и явное моделирование связей между любыми двумя позициями.

Принцип работы. Для последовательности входных векторов формируются три набора представлений: **Query** (запрос) Q , **Key** (ключ) K , **Value** (значение) V — как линейные проекции входа: $Q = XW^Q$, $K = XW^K$, $V = XW^V$. Масштабированное скалярное внимание (scaled dot-product attention) вычисляется следующим образом: сначала считается произведение QK^T , делится на корень из размерности ключей, применяется softmax для получения весов внимания, которые умножаются на V . Матрица QK^T даёт оценки близости каждой позиции ко всем остальным; после softmax получаются веса внимания, которыми взвешиваются векторы V . Таким образом, каждая позиция обновляет своё представление как взвешенную сумму значений по всей последовательности. **Многоголовое внимание** (multi-head): несколько таких блоков с разными проекциями W^Q , W^K , W^V работают параллельно, их выходы конкатенируются и проецируются в итоговое представление. В полной архитектуре используются кодировщик и декодировщик из нескольких таких слоёв с остаточными связями и слоями нормализации; позиции элементов кодируются отдельно (позиционное кодирование), так как сам по себе механизм внимания не различает порядок.

Применение Transformer в прогнозировании финансовых временных рядов. В работе [11] исследуется применение архитектур Transformer для прогнозирования финансовых временных рядов. Механизм самовнимания в Transformer позволяет модели явно определять, какие исторические моменты времени наиболее релевантны для прогнозирования текущего значения, что особенно важно в финансовых данных, где различные временные периоды могут иметь различную значимость в зависимости от рыночных условий. Transformer-модели способны параллельно обрабатывать всю последовательность, что ускоряет обучение по сравнению с рекуррентными сетями, и могут моделировать долгосрочные зависимости без ограничений, связанных с затуханием градиента.

В финансовом контексте механизм внимания позволяет модели динамически фокусироваться на различных временных масштабах: краткосрочных флуктуациях, среднесрочных трендах и долгосрочных паттернах. Это особенно полезно для прогнозирования цен акций, где важно учитывать как недавние изменения цен, так и исторические паттерны, которые могут повторяться. Для адаптации к временным рядам и финансам применяют варианты с ограничением внимания по окну или специализированным позиционным кодированием, учитывающим временную структуру финансовых данных.

В проекте планируется использовать модели на основе Transformer (или их модификации для одномерных рядов) как один из классов кандидатов для прогнозирования цен акций на Московской бирже и сравнение с RNN/LSTM/GRU и CNN.

1.5 Формирование портфеля и оптимизация по риску

Для формирования инвестиционного портфеля на основе прогнозов модели планируется опираться на классическую постановку оптимизации по Марковицу [1]: минимизация дисперсии портфеля при заданной целевой доходности:

минимум по w величины $w^T \Sigma w$ при условиях $\mu^T w \geq r_{target}$ и $\sum_{i=1}^n w_i = 1$,

где w — вектор весов активов, Σ — ковариационная матрица доходностей, μ — вектор ожидаемых доходностей. Ожидаемые доходности и ковариации могут оцениваться по историческим данным и/или с учётом прогнозов обученных моделей.

Известные ограничения модели Марковица — чувствительность к неточной оценке параметров и нестабильность весов. Для устойчивой оценки ковариационной матрицы применимы методы регуляризации, например, хорошо обусловленные оценки большой размерности [14]. В проекте планируется использовать подобные подходы при расчёте весов портфеля и ограничениях на риск и диверсификацию.

1.6 Метрики качества прогноза и эффективности стратегии

Качество моделей прогнозирования планируется оценивать метриками ошибки восстановления ряда: **MAE** (средняя абсолютная ошибка) и **RMSE** (среднеквадратичная ошибка). Для оценки эффективности торгового агента и сформированного портфеля используются финансовые метрики.

Коэффициент Шарпа [15]: $SR = \frac{R - r_f}{\sigma}$ — отношение избыточной доходности к стандартному отклонению (доходность на единицу риска).

Коэффициент Калмара [16]: $CR = \frac{R}{MDD}$ — отношение доходности к максимальной просадке (MDD).

При множественной проверке стратегий для корректировки за выборку применяется дефлированный коэффициент Шарпа [17]. Валидация и сравнение стратегий выполняются методом бэктестирования на исторических данных [18].

Применение методов машинного обучения к прогнозированию на российском фондовом рынке рассматривается, в частности, в [2]; в данной работе фокус делается на сочетании прогноза цен на МОЕХ, формирования портфеля и автоматизированного торгового агента с последующей оценкой по бэктесту.

2 План работы

2.1 Подготовка и анализ данных

На первом этапе планируется собрать датасет по ликвидным акциям Московской биржи, объёмы торгов, данные по сделкам и участникам. Исходные ряды будут выровнены по времени, устранены пропуски и выбросы. Для выявления структурных сдвигов и разметки режимов рынка планируется привлечь методы обнаружения точек смены режима (Change Point Detection) и другие инструменты предобработки, доступные в библиотеках машинного обучения. Информация о типах участников сделок (розничные инвесторы, институциональные инвесторы, алготрейдеры, иностранные фонды) будет использоваться для обогащения признаков и анализа поведения различных групп участников в дальнейшем обучении и интерпретации результатов. В конце получим согласованный набор признаков и разбиение на обучающую, валидационную и тестовую выборки с соблюдением хронологического порядка и без утечки данных из будущего в прошлое.

2.2 Обучение моделей прогнозирования

На подготовленных данных планируется обучить несколько классов моделей прогнозирования цен акций: рекуррентные сети (LSTM, GRU, RNN), свёрточные архитектуры (CNN), модели на основе механизма внимания (Transformer). Для каждой архитектуры подбираются гиперпараметры и проводится обучение. Качество прогнозов оценивается на валидационной выборке по выбранным метрикам (MAE, RMSE). По результатам сравнения отбираются одна или несколько наилучших конфигураций, для них выполняется дообучение на расширенном объёме данных, эксперименты по улучшению (регуляризация, тонкая настройка гиперпараметров, ансамбли, комбинации моделей) и финальная оценка на тестовой выборке.

2.3 Формирование и оптимизация портфеля

После получения рабочей модели прогнозирования следующий этап это формирования портфеля. На основе предсказаний модели (исторической волатильности и взаимных корреляциях) определяются правила отбора бумаг и назначения весов с учётом ограничений на риск и диверсификацию. Итогом этапа является формализованная стратегия формирования портфеля, согласованная с выходом модели прогноза и готовая к использованию в торговом агенте.

2.4 Реализация торгового агента

На основе выбранной модели прогнозирования и правил формирования портфеля планируется реализовать торгового агента — программный модуль, который на каждом шаге получает текущее состояние рынка и прогнозы модели, определяет целевую структуру портфеля и генерирует сигналы на покупку или продажу бумаг. В агенте закладываются правила исполнения: как переходить от целевых весов к конкретным заявкам, с учётом ликвидности, комиссий и ограничений (минимальный лот, целочисленность количества бумаг). Реализуется логика управления риском: ограничение размера позиции, стоп-лоссы, ограничение просадки. Агент проектируется так, чтобы его можно было запускать как на исторических данных (для бэктеста), так и в режиме симуляции или интеграции с торговым API.

2.5 Бэктестирование и оценка результатов

После реализации торгового агента планируется провести бэктестирование на исторических данных Московской биржи: агент последовательно обрабатывает тестовый период, получает прогнозы модели и формирует сделки в соответствии с правилами портфеля. Симулируется исполнение заявок и накопление капитала. По результатам прогона вычисляются метрики доходности и риска, такие как : доходность, коэффициент Шарпа и другие показатели. Оценивается чувствительность результатов к параметрам стратегии и к выбору периода тестирования.

Список литературы

- [1] H. Markowitz, «Portfolio Selection», *The Journal of Finance*, т. 7, вып. 1, сс. 77–91, 1952.
- [2] Е. А. Федорова и В. А. Черепенко, «Применение методов машинного обучения для прогнозирования доходности акций на российском фондовом рынке», *Экономический журнал ВШЭ*, т. 24, вып. 4, сс. 560–590, 2020.
- [3] C. Truong, L. Oudre, и N. Vayatis, «Selective review of offline change point detection methods», *arXiv preprint*, 2018.
- [4] «An Evaluation of Change Point Detection Algorithms», 2024.
- [5] J. L. Elman, «Finding Structure in Time», *Cognitive Science*, т. 14, вып. 2, сс. 179–211, 1990, doi: [10.1207/s15516709cog1402_1](https://doi.org/10.1207/s15516709cog1402_1).
- [6] K. Greff, R. K. Srivastava, J. Koutník, B. R. Steunebrink, и J. Schmidhuber, «LSTM: A Search Space Odyssey», *IEEE Transactions on Neural Networks and Learning Systems*, т. 28, вып. 10, сс. 2222–2232, 2017.
- [7] S. Siami-Namini, N. Tavakoli, и A. Siami Namin, «A Comparative Analysis of Forecasting Financial Time Series Using ARIMA, LSTM, and BiLSTM», 2019.
- [8] K. Cho, B. van Merriënboer, Ç. Gülçehre, F. Bougares, H. Schwenk, и Y. Bengio, «Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation», *arXiv preprint*, 2014.
- [9] «Integrated GARCH-GRU in Financial Volatility Forecasting», 2024.
- [10] Y. Liu, C. Gong, L. Yang, и Y. Chen, «DSTP-RNN: a dual-stage two-phase attention-based recurrent neural networks for long-term and multivariate time series prediction», 2019.
- [11] «Financial Time Series Forecasting using CNN and Transformer», 2024.
- [12] G. Lai, W.-C. Chang, Y. Yang, и H. Liu, «Modeling Long- and Short-Term Temporal Patterns with Deep Neural Networks», *arXiv preprint*, 2017.
- [13] A. Vaswani и др., «Attention Is All You Need», *arXiv preprint*, 2017.
- [14] O. Ledoit и M. Wolf, «A well-conditioned estimator for large-dimensional covariance matrices», *Journal of Multivariate Analysis*, т. 88, вып. 2, сс. 365–411, 2004.
- [15] W. F. Sharpe, «The Sharpe Ratio», *The Journal of Portfolio Management*, т. 21, вып. 1, сс. 49–58, 1994.
- [16] T. W. Young, «Calmar Ratio: A Smoother Tool», *Futures Magazine*, т. 20, вып. 1, 1991.

- [17] D. H. Bailey и M. López de Prado, «The Deflated Sharpe Ratio: Correcting for Selection Bias», *The Journal of Portfolio Management*, т. 40, вып. 5, сс. 94–107, 2014.
- [18] R. Pardo, *The Evaluation and Optimization of Trading Strategies*, 2nd изд. Wiley, 2008.