

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

УДК 004.85:336.763

Отчет об исследовательском проекте на тему:
Управление портфелем валютных и индексных фьючерсов
на основе методов машинного обучения с подкреплением

(промежуточный, этап 1)

Выполнил студент:

группы #БПИ221, 3 курса

Кортунов Дмитрий Вадимович

Принял руководитель проекта:

Иванов Иван Иванович

Доцент, к.э.н.

Факультет компьютерных наук НИУ ВШЭ

Москва 2026

Содержание

Аннотация	3
Ключевые слова	3
Введение	4
1 Обзор литературы	5
1.1 Классические методы оптимизации портфеля	5
1.2 Машинное обучение с подкреплением	5
1.3 Применение RL в финансах	5
1.4 Метрики оценки эффективности	5
2 План дальнейшей работы	7
2.1 Разработка архитектуры системы	7
2.2 Формализация среды	7
2.3 План экспериментов	7
2.4 Программная реализация	7
2.5 Ожидаемые результаты	7
2.6 Календарный план	8
Список литературы	9

Аннотация

Данная работа посвящена разработке программного обеспечения для управления инвестиционным портфелем валютных и индексных фьючерсов на основе методов машинного обучения с подкреплением. В качестве основных алгоритмов планируется использовать Proximal Policy Optimization (PPO) и Deep Q-Networks (DQN) с интеграцией NLP-сентимент-анализа.

Планируется провести сравнительный анализ эффективности предложенных стратегий с классическими подходами через rolling-window бэктестирование. Для оценки результатов будут применяться метрики: коэффициент Шарпа, коэффициент Калмара и максимальная просадка.

Ожидаемая новизна работы — разработка гибридной архитектуры, объединяющей RL-алгоритмы и NLP-анализ финансовых новостей для динамического управления портфелем фьючерсов.

Ключевые слова

Машинное обучение с подкреплением, PPO, DQN, оптимизация портфеля, фьючерсы, сентимент-анализ, NLP, коэффициент Шарпа, бэктестирование

Введение

Современные финансовые рынки характеризуются высокой волатильностью и сложной нелинейной динамикой. Традиционные методы оптимизации портфеля, основанные на теории Марковица [1], имеют существенные ограничения: предположения о стационарности и нормальности распределений часто не выполняются на практике.

Рынок фьючерсов представляет особый интерес для применения методов машинного обучения благодаря высокой ликвидности, возможности использования кредитного плеча и открытия коротких позиций [2].

Актуальность исследования обусловлена успехами методов машинного обучения с подкреплением в задачах последовательного принятия решений [3] и развитием NLP-технологий для анализа финансовых текстов [4].

Объект исследования — методы оптимизации инвестиционного портфеля фьючерсов.

Предмет исследования — применение методов машинного обучения с подкреплением для управления портфелем валютных и индексных фьючерсов.

Гипотеза: использование методов RL в сочетании с NLP-сентимент-анализом повышает эффективность управления портфелем фьючерсов по сравнению с классическими подходами.

Цель работы — разработка алгоритмов и программного обеспечения для управления портфелем валютных и индексных фьючерсов на основе машинного обучения с подкреплением.

Задачи:

1. Провести анализ современных методов оптимизации портфеля фьючерсов и методов машинного обучения с подкреплением.
2. Выбрать и обосновать оптимальные методы (PPO, DQN) и метрики оценки эффективности.
3. Предложить модель оптимизации портфеля и разработать программное обеспечение.
4. Провести эксперименты на исторических данных и оценить эффективность.
5. Сформулировать рекомендации по практическому применению.

Ограничения: анализ будет проводиться на данных Московской биржи (MOEX) и СМЕ за период 2018–2025 гг.

1 Обзор литературы

1.1 Классические методы оптимизации портфеля

Задача оптимизации портфеля была впервые формализована Г. Марковицем [1] как минимизация дисперсии при заданной доходности:

$$\min_w w^T \Sigma w \quad \text{при} \quad \mu^T w \geq r_{\text{target}}, \quad \sum_{i=1}^n w_i = 1, \quad (1.1)$$

где w — вектор весов, Σ — ковариационная матрица, μ — ожидаемые доходности.

Несмотря на теоретическую элегантность, модель имеет ограничения [5]: чувствительность к оценке параметров, предположение о стационарности и нормальности распределений.

Применительно к фьючерсам возникают дополнительные особенности: срочность контрактов, маржинальная торговля и возможность коротких позиций [2].

1.2 Машинное обучение с подкреплением

Reinforcement Learning (RL) — парадигма обучения через взаимодействие со средой с целью максимизации кумулятивного вознаграждения [3]. Задача описывается как марковский процесс принятия решений (MDP).

Deep Q-Networks (DQN) [6] аппроксимирует функцию ценности действия с помощью нейронной сети. Ключевые инновации: experience replay и target network. Ограничение — работа с дискретным пространством действий.

Proximal Policy Optimization (PPO) [7] — алгоритм оптимизации политики с ограничением изменений на каждом шаге. Преимущества: стабильность обучения и работа с непрерывными действиями.

1.3 Применение RL в финансах

Работа [8] впервые применила RL для торговых стратегий. Современные исследования [9], [10] используют глубокое обучение для извлечения признаков из рыночных данных.

Библиотека FinRL [11] предоставляет готовые компоненты для построения торговых агентов. Работа [12] предлагает ансамблевые стратегии для повышения робастности.

Отдельное направление — интеграция NLP-анализа [13]. Модель FinBERT [14] позволяет извлекать сентимент из финансовых текстов.

Для российского рынка исследования ML-методов представлены в [15], однако специализированных работ по применению RL для фьючерсов на MOEX не обнаружено, что определяет новизну данного исследования.

1.4 Метрики оценки эффективности

Для оценки торговых стратегий используются метрики [16]:

Коэффициент Шарпа: $SR = \frac{R - r_f}{\sigma}$ — доходность на единицу риска.

Коэффициент Калмара [17]: $CR = \frac{R}{MDD}$ — доходность на единицу просадки.

Для валидации применяется rolling-window бэктестирование [18] и анализ дефлированного Шарпа [19].

2 План дальнейшей работы

2.1 Разработка архитектуры системы

Планируется разработать систему со следующими компонентами:

1. **Модуль данных** — сбор и обработка котировок MOEX/CME.
2. **NLP-модуль** — сентимент-анализ на базе FinBERT.
3. **RL-агенты** — реализация PPO и DQN.
4. **Модуль бэктестирования** — оценка эффективности стратегий.

2.2 Формализация среды

Пространство состояний: исторические цены, объёмы, позиции портфеля, технические индикаторы, NLP-сентимент.

Пространство действий:

- PPO: непрерывные веса $a \in [-1, 1]^n$
- DQN: дискретные сигналы $a \in \{-1, 0, 1\}^n$

Функция вознаграждения: логарифмическая доходность с учётом транзакционных издержек.

2.3 План экспериментов

Данные:

- MOEX: фьючерсы Si (USD/RUB), MXI (IMOEX), BR (Brent)
- CME: ES (S&P 500), 6E (EUR/USD), CL (Oil)
- Период: 2018–2025, разбиение: train 70%, val 15%, test 15%

Эксперименты:

1. Сравнение PPO и DQN между собой
2. Сравнение с бенчмарками: Buy-and-Hold, Equal Weight, Markowitz
3. Оценка вклада NLP-сентимента (ablation study)
4. Rolling-window тесты на устойчивость

Метрики: Sharpe Ratio, Calmar Ratio, Maximum Drawdown, Win Rate.

2.4 Программная реализация

Планируется использовать:

- Python, PyTorch [20] для нейронных сетей
- Stable-Baselines3 [21] для RL-алгоритмов
- Transformers (FinBERT) для NLP
- OpenAI Gym [22] для среды

2.5 Ожидаемые результаты

1. Реализованное ПО для управления портфелем фьючерсов на основе RL.
2. Сравнительный анализ PPO и DQN с классическими методами.
3. Оценка влияния NLP-сентимента на эффективность стратегий.
4. Рекомендации по практическому применению.

2.6 Календарный план

Этап	Срок
Сбор и подготовка данных	Февраль 2026
Разработка RL-агентов и среды	Март 2026
Интеграция NLP-модуля	Март 2026
Проведение экспериментов	Апрель 2026
Анализ результатов, написание отчёта	Май 2026

Таблица 2.1. Календарный план работы

Список литературы

- [1] H. Markowitz, «Portfolio Selection», *The Journal of Finance*, т. 7, вып. 1, сс. 77–91, 1952.
- [2] J. C. Hull, *Options, Futures, and Other Derivatives*, 10th изд. Pearson, 2018.
- [3] R. S. Sutton и A. G. Barto, «Reinforcement Learning: An Introduction», 2018.
- [4] J. Devlin, M.-W. Chang, K. Lee, и K. Toutanova, «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding», в *Proceedings of NAACL-HLT*, 2019, сс. 4171–4186.
- [5] O. Ledoit и M. Wolf, «A well-conditioned estimator for large-dimensional covariance matrices», *Journal of Multivariate Analysis*, т. 88, вып. 2, сс. 365–411, 2004.
- [6] V. Mnih, K. Kavukcuoglu, D. Silver, и others, «Human-level control through deep reinforcement learning», *Nature*, т. 518, вып. 7540, сс. 529–533, 2015.
- [7] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, и O. Klimov, «Proximal Policy Optimization Algorithms». 2017 г.
- [8] J. Moody и M. Saffell, «Learning to trade via direct reinforcement», *IEEE Transactions on Neural Networks*, т. 12, вып. 4, сс. 875–889, 2001.
- [9] Y. Deng, F. Bao, Y. Kong, Z. Ren, и Q. Dai, «Deep direct reinforcement learning for financial signal representation and trading», *IEEE Transactions on Neural Networks and Learning Systems*, т. 28, вып. 3, сс. 653–664, 2017.
- [10] Z. Jiang, D. Xu, и J. Liang, «A deep reinforcement learning framework for the financial portfolio management problem». 2017 г.
- [11] X.-Y. Liu, H. Yang, Q. Chen, и others, «FinRL: A deep reinforcement learning library for automated stock trading», в *ACM International Conference on AI in Finance*, 2020, сс. 1–9.
- [12] H. Yang, X.-Y. Liu, S. Zhong, и A. Walid, «Deep reinforcement learning for automated stock trading: An ensemble strategy». 2020 г.
- [13] J. Bollen, H. Mao, и X. Zeng, «Twitter mood predicts the stock market», *Journal of Computational Science*, т. 2, вып. 1, сс. 1–8, 2011.
- [14] D. Araci, «FinBERT: Financial Sentiment Analysis with Pre-trained Language Models». 2019 г.
- [15] Е. А. Федорова и В. А. Черепенко, «Применение методов машинного обучения для прогнозирования доходности акций на российском фондовом рынке», *Экономический журнал ВШЭ*, т. 24, вып. 4, сс. 560–590, 2020.
- [16] W. F. Sharpe, «The Sharpe Ratio», *The Journal of Portfolio Management*, т. 21, вып. 1, сс. 49–58, 1994.
- [17] T. W. Young, «Calmar Ratio: A Smoother Tool», *Futures Magazine*, т. 20, вып. 1, 1991.
- [18] R. Pardo, *The Evaluation and Optimization of Trading Strategies*, 2nd изд. Wiley, 2008.
- [19] D. H. Bailey и M. López de Prado, «The Deflated Sharpe Ratio: Correcting for Selection Bias», *The Journal of Portfolio Management*, т. 40, вып. 5, сс. 94–107, 2014.

- [20] A. Paszke, S. Gross, F. Massa, и others, «PyTorch: An Imperative Style, High-Performance Deep Learning Library». 2019 г.
- [21] A. Raffin, A. Hill, A. Gleave, и others, «Stable-Baselines3: Reliable Reinforcement Learning Implementations». 2021 г.
- [22] G. Brockman, V. Cheung, L. Pettersson, и others, «OpenAI Gym». 2016 г.